

PYTHON

PCAD – CERTIFIED ASSOCIATE DATE ANALYST WITH PYTHON

CHAPTER 3 – STATISTICAL ANALYSIS

CHAPTER 3 – STATISTICAL ANALYSIS

Descriptive Statistics

CHAPTER 3 – STATISTICAL ANALYSIS

- Comprender y aplicar medidas estadísticas en el análisis de datos

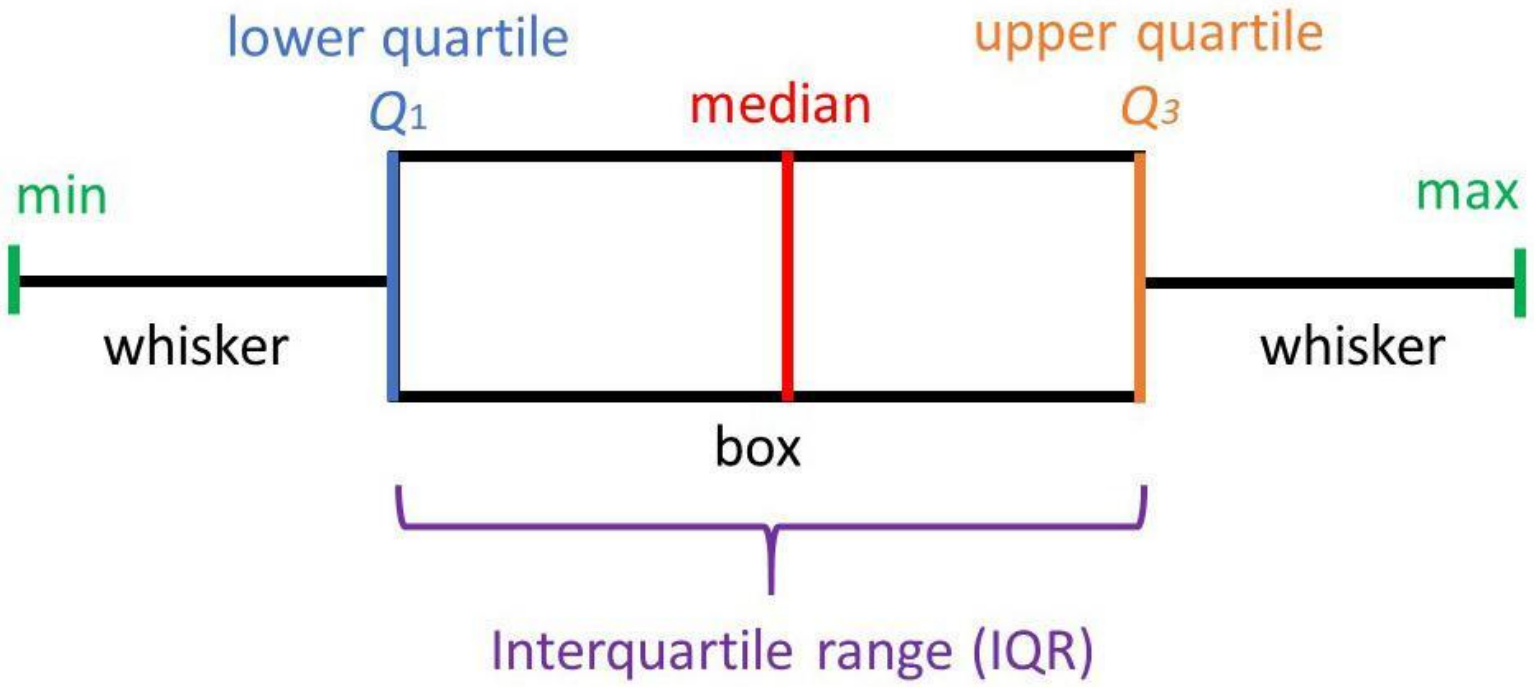
- A. Medidas de tendencia central y dispersión
  - **Medidas de tendencia central**. Describen el valor representativo o "centro" de un conjunto de datos.
    - Media (Mean) → Promedio aritmético de los datos.
    - Mediana (Median) → Valor central cuando los datos están ordenados.
    - Moda (Mode)→ Valor que aparece con mayor frecuencia.

CHAPTER 3 – STATISTICAL ANALYSIS

- Comprender y aplicar medidas estadísticas en el análisis de datos
- A. Medidas de tendencia central y dispersión
  - **Medidas de dispersión**. Indican cuánto varían los datos respecto al centro.
    - Rango (Range) → Diferencia entre el valor máximo y mínimo.
    - Varianza (Variance) → Mide la dispersión promedio respecto a la media.
    - Desviación estándar (Standard Deviation) → Raíz cuadrada de la varianza; expresa dispersión en las mismas unidades de los datos.
      - Poblacional → Se dispone de todos los datos (100%) de la población.
      - Muestral → Se dispone de una muestra representativa de la población. Se divide entre n−1 para corregir la estimación algo menor de la dispersión frente a la poblacional.
    - Rango intercuartílico (IQR) → El rango intercuartílico (Interquartile Range) es una medida estadística que nos dice cuánto de dispersos están el 50% de los datos centrales de un grupo. Ignora los extremos y, por lo tanto, los outliers
  - **Interpretación**
    - Baja dispersión → datos más homogéneos.
    - Alta dispersión → mayor variabilidad e incertidumbre.

CHAPTER 3 – STATISTICAL ANALYSIS

- Comprender y aplicar medidas estadísticas en el análisis de datos



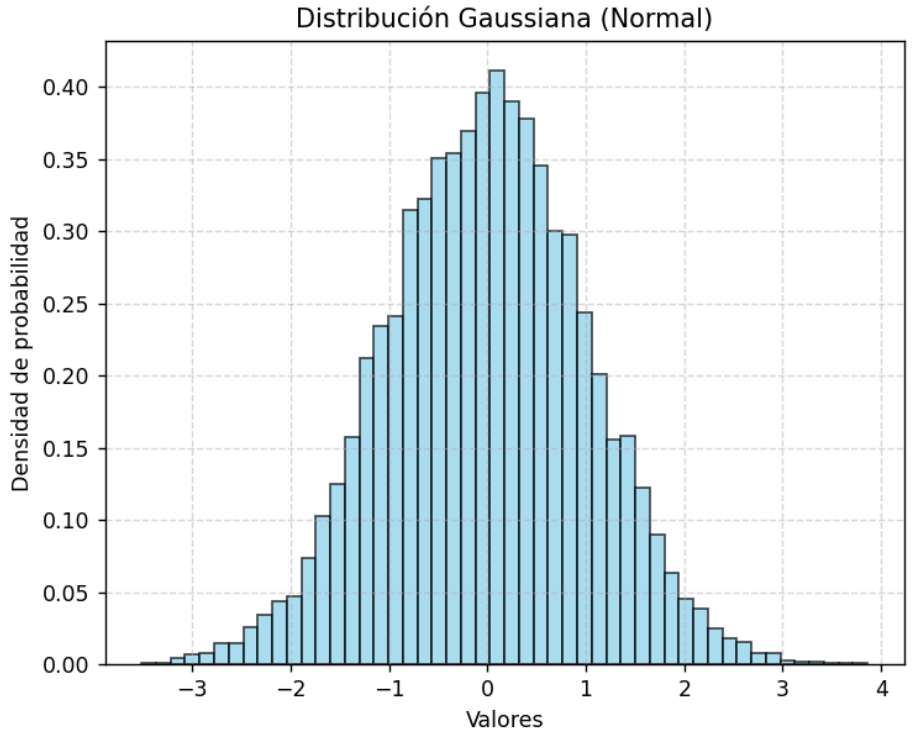
CHAPTER 3 – STATISTICAL ANALYSIS

- Comprender y aplicar medidas estadísticas en el análisis de datos
- A. Medidas de tendencia central y dispersión

Medida Estadística	Python Nativo (statistics / básico)	NumPy	Pandas
Media	statistics.mean(datos)	np.mean(datos)	df.mean()
Mediana	statistics.median(datos)	np.median(datos)	df.median()
Moda	statistics.mode(datos)	No tiene función directa integrada	df.mode()
Rango	max(datos) - min(datos)	np.ptp(datos)	df.max() - df.min()
Varianza	statistics.variance(datos) (muestral) statistics.pvariance(datos) (poblacional)	np.var(datos) (poblacional por defecto) np.var(datos, ddof=1) (muestral)	df.var() (muestral por defecto) df.var(ddof=0) (poblacional)
Desviación Estándar	statistics.stdev(datos) (muestral) statistics.pstdev(datos) (poblacional)	np.std(datos) (poblacional por defecto) np.std(datos, ddof=1) (muestral)	df.std() (muestral por defecto) df.std(ddof=0) (poblacional)
Rango Intercuartílico (IQR)	statistics.quantiles(datos, n=4) q1 = cuartiles[0] q3 = cuartiles[2]	np.percentile(datos, 75) - np.percentile(datos, 25)	df.quantile(0.75) - df.quantile(0.25)

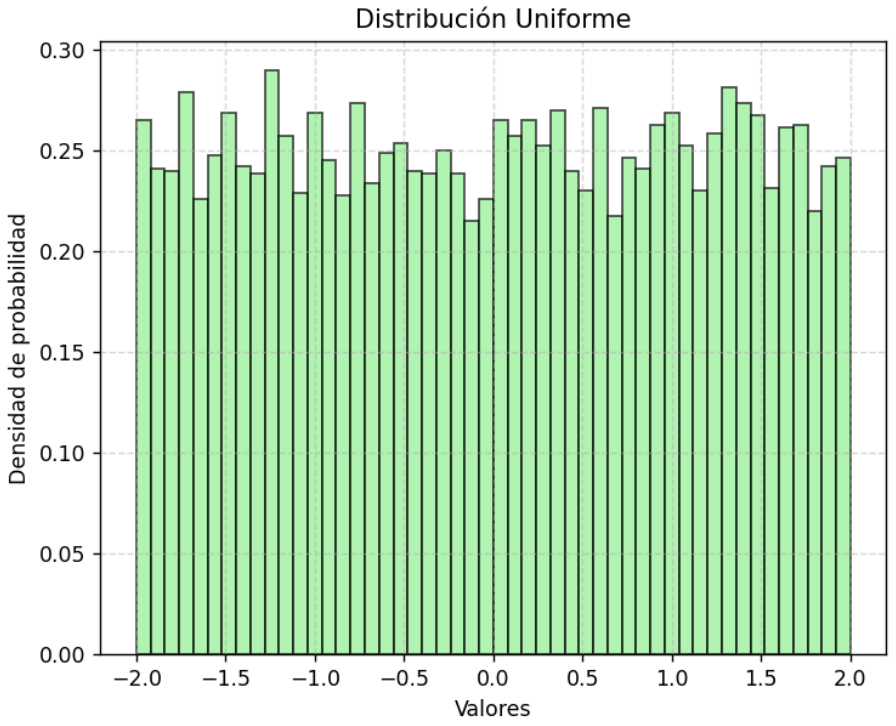
CHAPTER 3 – STATISTICAL ANALYSIS

- Comprender y aplicar medidas estadísticas en el análisis de datos
- B. Distribuciones estadísticas fundamentales e interpretación
  - **Distribución Gaussiana (Normal)**
  - Características:
    - Forma de campana simétrica.
    - La media, mediana y moda coinciden.
    - Muchas variables naturales siguen esta distribución:
      - Altura
      - Peso
      - Errores de medición
    - Interpretación:
      - Valores cercanos a la media son más frecuentes.
      - Valores extremos son menos probables.



CHAPTER 3 – STATISTICAL ANALYSIS

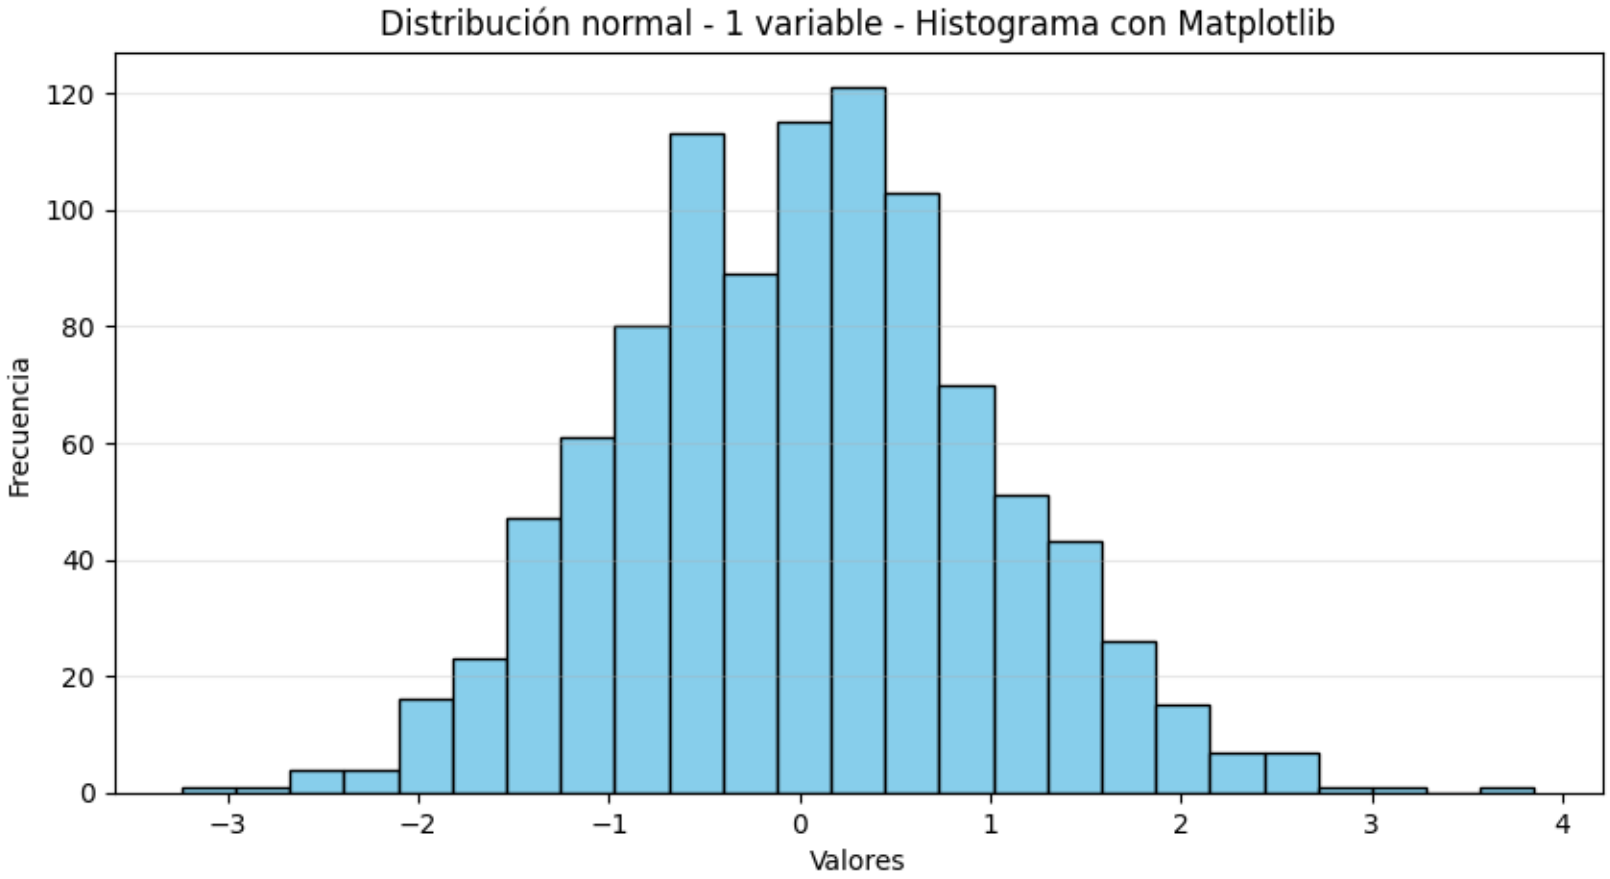
- Comprender y aplicar medidas estadísticas en el análisis de datos
- B. Distribuciones estadísticas fundamentales e interpretación
  - **Distribución Uniforme**
  - Características:
    - Todos los valores tienen la misma probabilidad.
    - Distribución plana.
      - Ejemplos:
        - Lanzamiento ideal de un dado.
        - Números aleatorios.



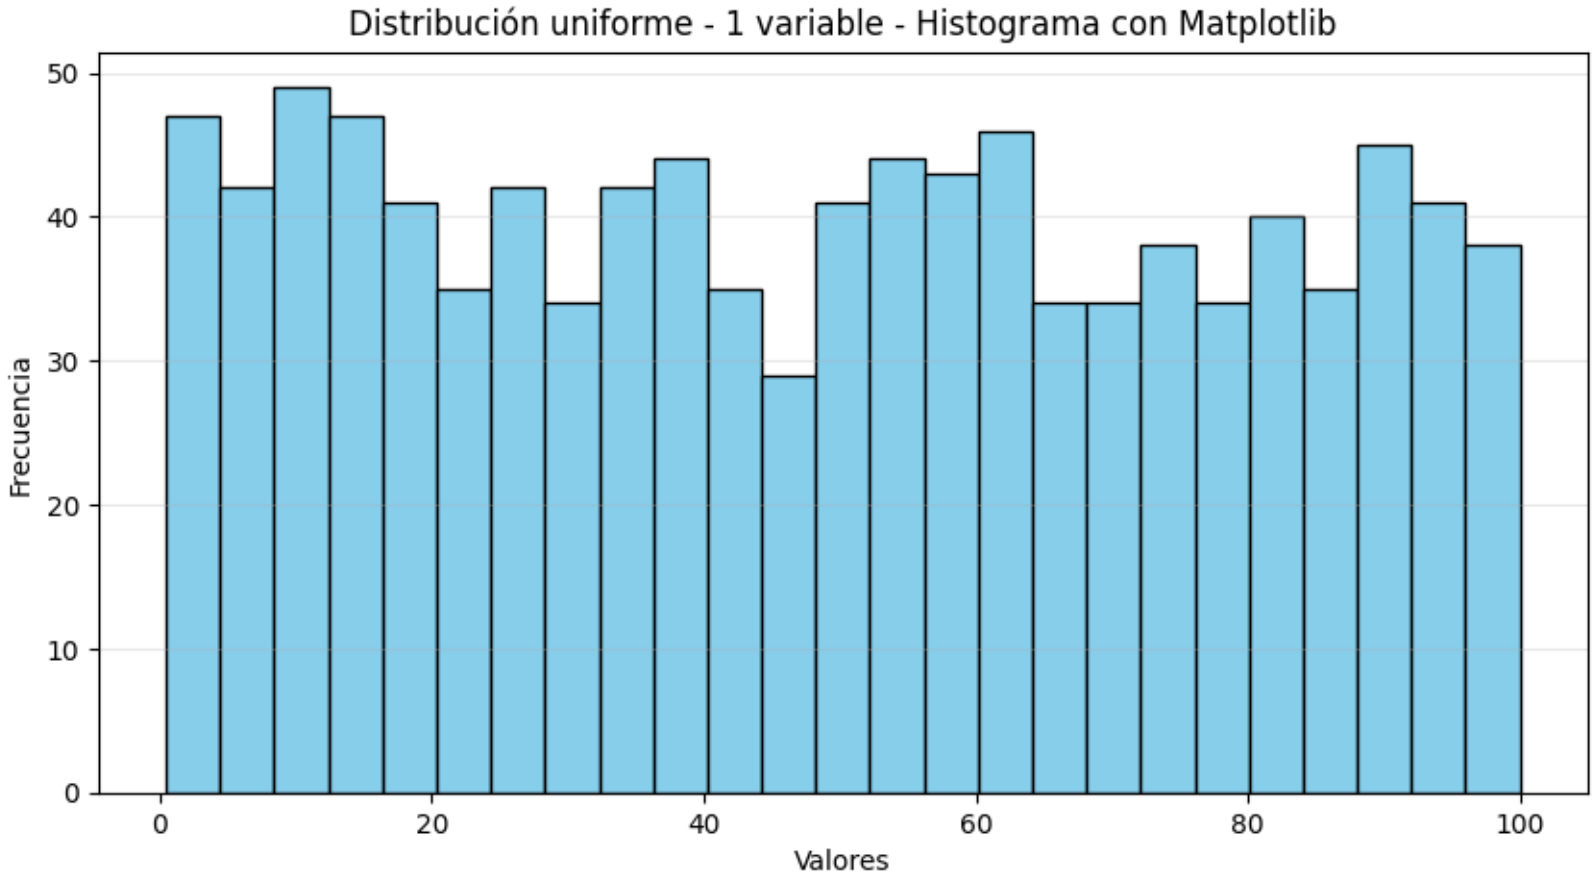
CHAPTER 3 – STATISTICAL ANALYSIS

- Comprender y aplicar medidas estadísticas en el análisis de datos
- B. Distribuciones estadísticas fundamentales e interpretación
  - **Interpretación de tendencias en diferentes contextos.**
    - **A. Contexto Univariante (Una sola variable).** Analiza una única variable para identificar su comportamiento o distribución.
      - Tendencia gaussiana: Los valores se concentran alrededor de la media y disminuyen hacia los extremos. Significa que predominan los valores centrales y hay pocos extremos. Gráfico: histograma con forma de campana.
      - Tendencia uniforme: Todos los valores tienen una frecuencia similar. Significa que ningún valor predomina. Gráfico: histograma con barras de alturas parecidas.
    - **B. Contexto Bivariante (Dos variables).** Estudia la relación entre dos variables para identificar si están relacionadas.
      - Tendencia gaussiana: Los valores se concentran alrededor de un punto central. Significa que existe una zona con mayor concentración de datos. Gráfico: diagrama de dispersión con forma ovalada, con más puntos en el centro.
      - Tendencia uniforme: Los valores se distribuyen de forma similar en el rango de ambas variables. Significa que no hay una zona claramente predominante. Gráfico: diagrama de dispersión con puntos repartidos uniformemente.

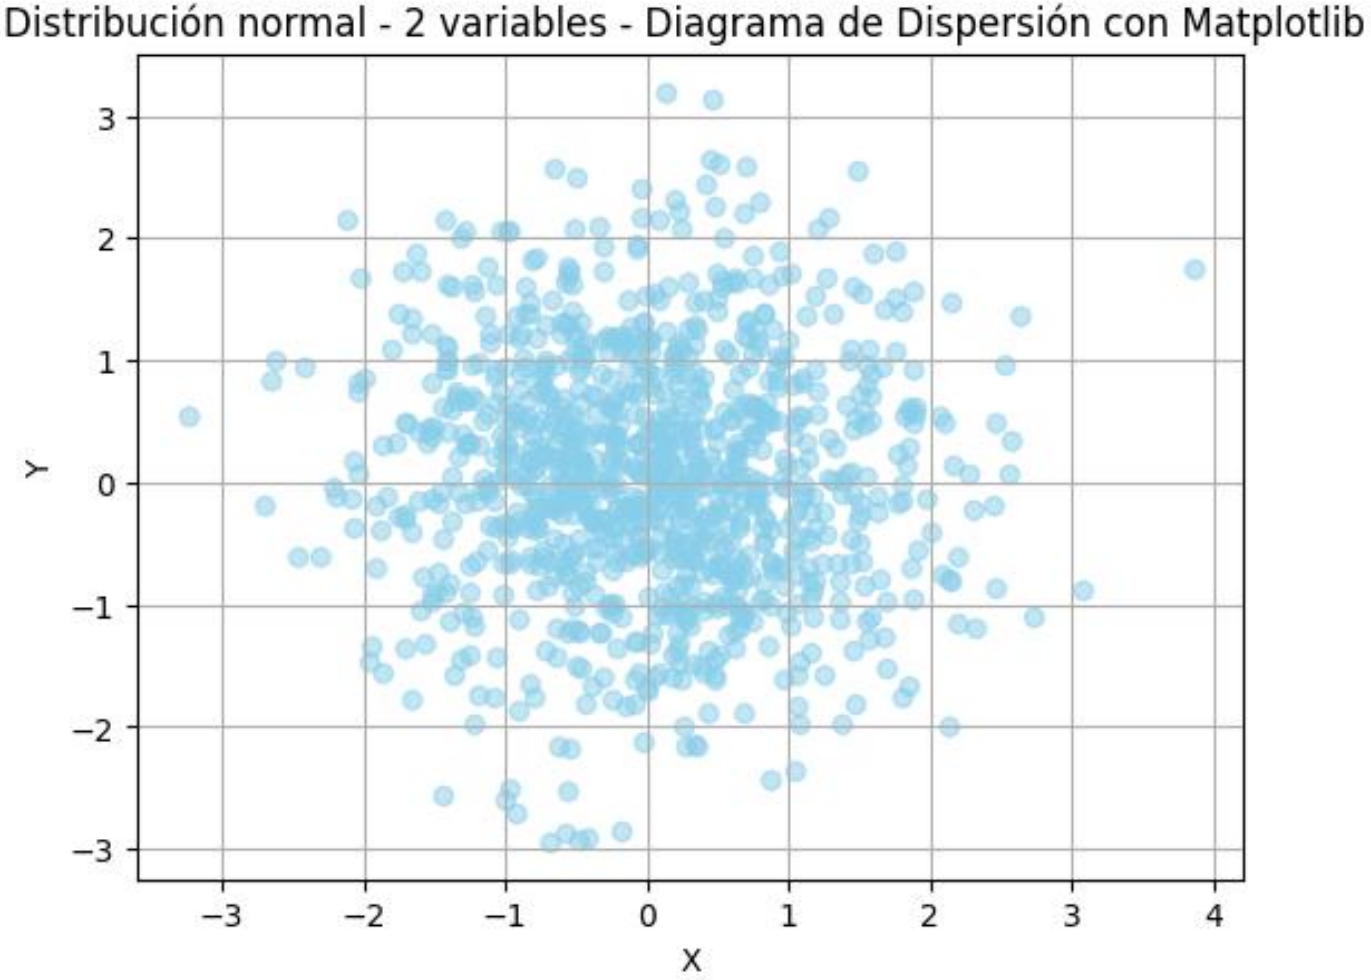
CHAPTER 3 – STATISTICAL ANALYSIS



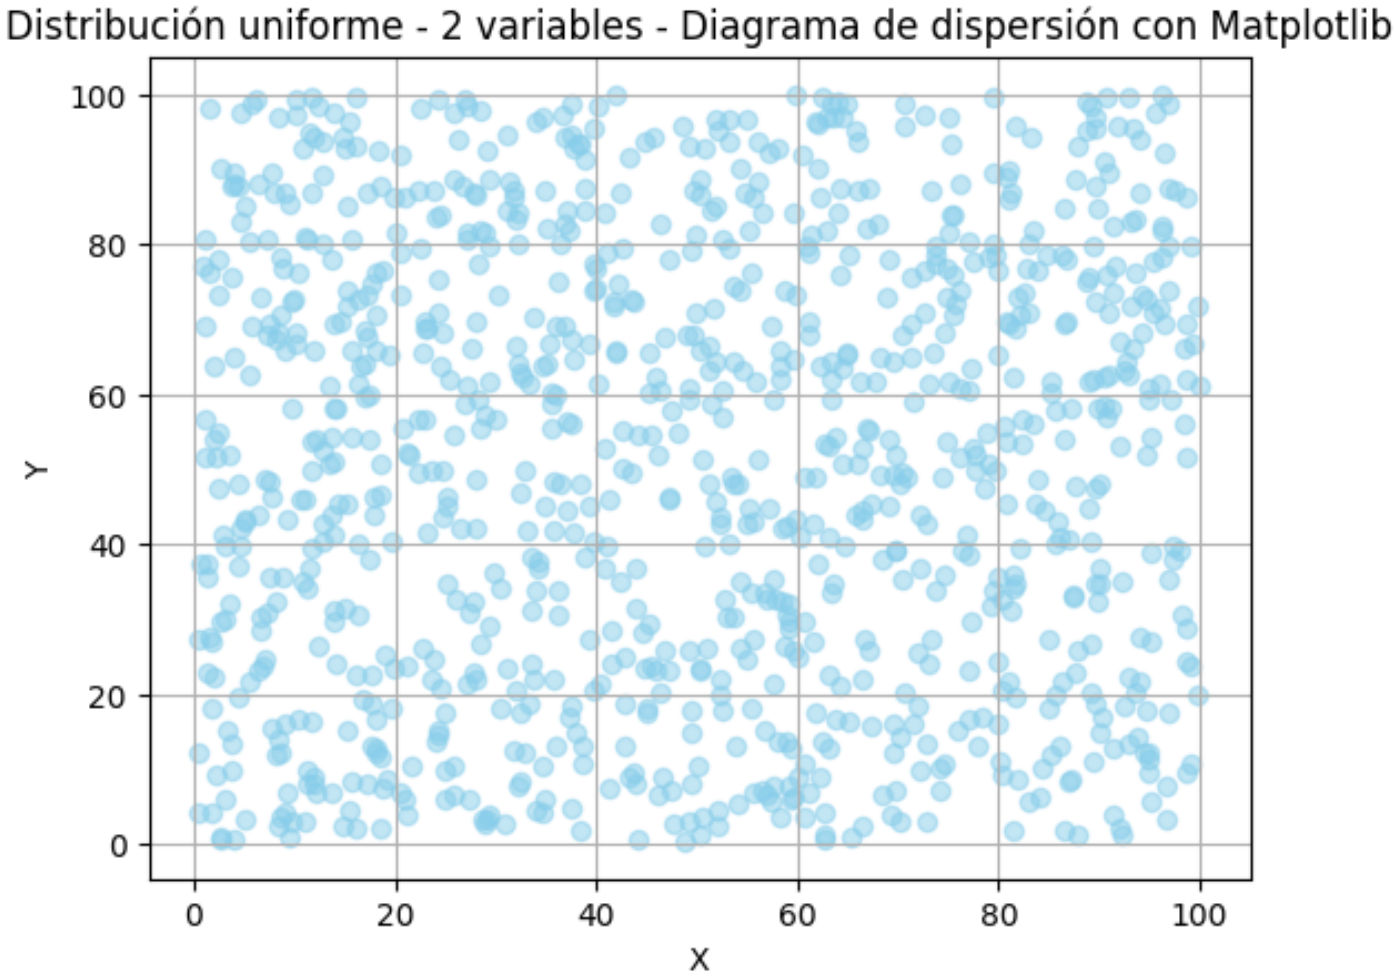
CHAPTER 3 – STATISTICAL ANALYSIS



CHAPTER 3 – STATISTICAL ANALYSIS



CHAPTER 3 – STATISTICAL ANALYSIS



CHAPTER 3 – STATISTICAL ANALYSIS

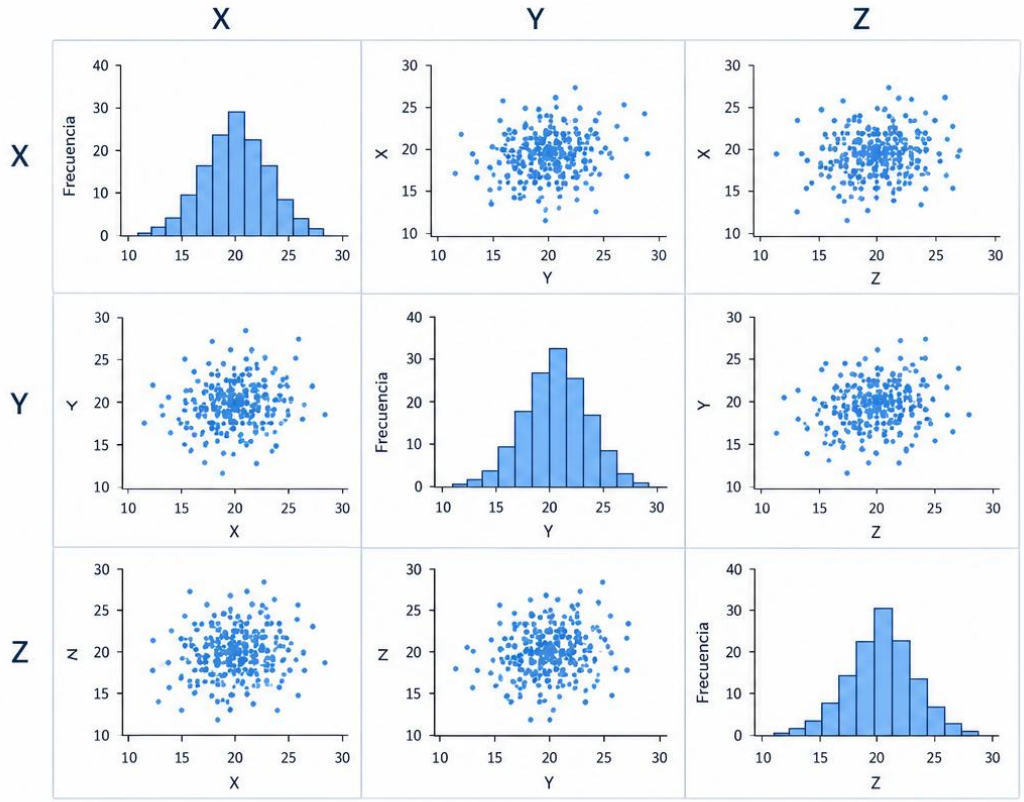
- Comprender y aplicar medidas estadísticas en el análisis de datos
- B. Distribuciones estadísticas fundamentales e interpretación
  - **Interpretación de tendencias en diferentes contextos.**
    - **C. Contexto Multivariante (Tres o más variables).** Analiza varias variables simultáneamente para identificar relaciones y patrones complejos.
      - Tendencia gaussiana: Los valores se agrupan alrededor de sus medias. Significa que predominan los valores centrales y hay menos valores extremos. Gráfico: matriz de diagramas de dispersión con nubes de puntos concentradas en el centro.
      - Tendencia uniforme: Los valores se distribuyen de forma similar en el rango de las variables. Significa que las combinaciones de valores tienen una presencia parecida. Gráfico: diagramas de dispersión con puntos repartidos de manera homogénea.

CHAPTER 3 – STATISTICAL ANALYSIS

Contexto multivariante – Tendencia gaussiana

Ejemplo con tres variables: X, Y y Z

Los valores se agrupan alrededor de sus medias, con menos valores extremos.



¿Qué muestra el gráfico?

Una matriz de diagramas de dispersión con tres variables (X, Y y Z).

En la diagonal, se muestran histogramas de cada variable. En los gráficos fuera de la diagonal, se observa la relación entre dos variables.

Tendencia gaussiana

Los valores de cada variable se agrupan alrededor de sus medias, formando nubes de puntos concentradas en el centro.

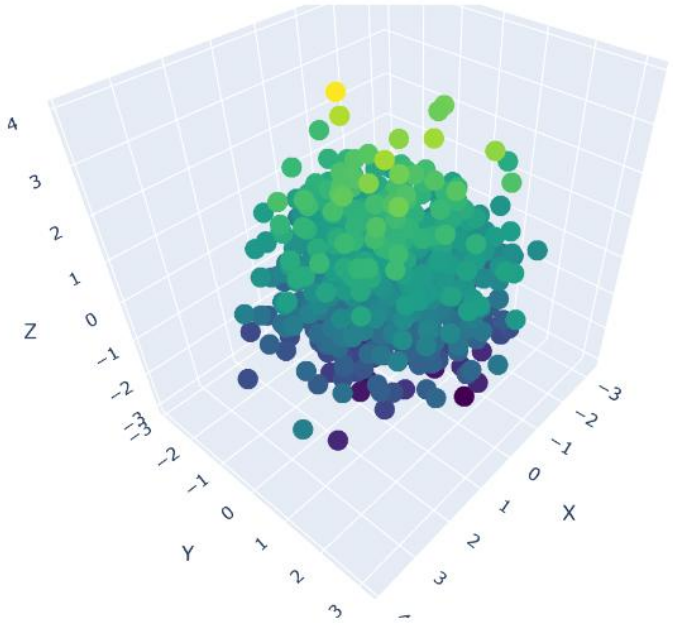
Significado

Predominan los valores centrales y hay menos valores extremos.

Tipo de gráfico

Matriz de diagramas de dispersión (con histogramas en la diagonal).

Diagrama de Dispersión 3D Interactivo (Rotable con el Ratón)

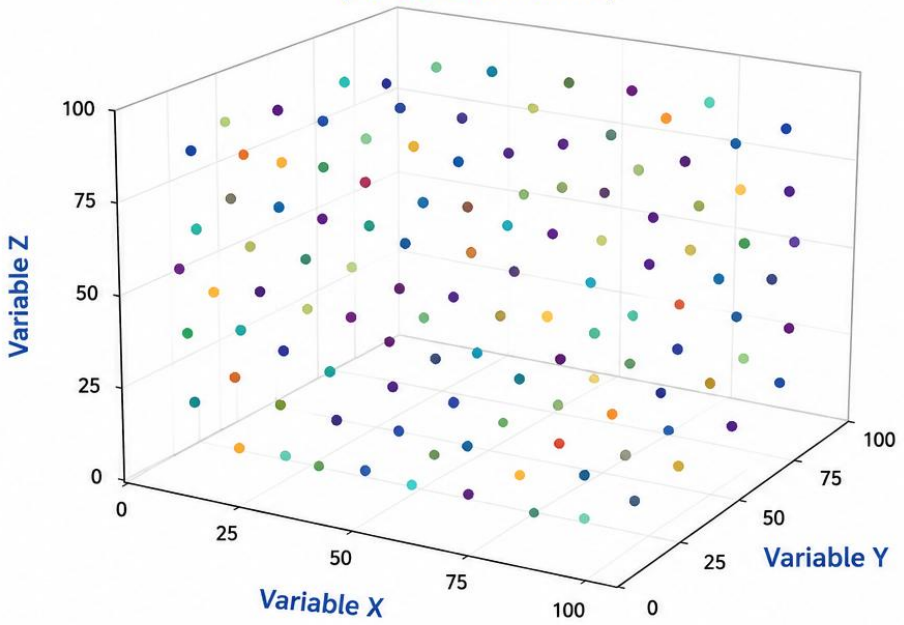


CHAPTER 3 – STATISTICAL ANALYSIS

Contexto Multivariante (Tres o más variables)

Se analizan varias variables simultáneamente para identificar relaciones y patrones complejos.

Diagrama de dispersión 3D (Tendencia uniforme)



Rango de las variables	Variable X	Variable Y	Variable Z
	0 – 100	0 – 100	0 – 100

Tendencia uniforme

Los valores se distribuyen de forma similar en el rango de las variables. Significa que las combinaciones de valores tienen una presencia parecida.

Interpretación

No se observan patrones de agrupamiento ni tendencias claras entre las variables. Cualquier combinación de valores es igualmente probable dentro del rango observado.

Gráfico recomendado

Diagramas de dispersión (3D o en múltiples pares) con puntos repartidos de manera homogénea.

Conclusión

La distribución uniforme indica ausencia de relación fuerte entre las variables y una diversidad equilibrada de combinaciones de valores.

En un contexto multivariante, una tendencia uniforme refleja una exploración equilibrada del espacio de datos.

CHAPTER 3 – STATISTICAL ANALYSIS

- Comprender y aplicar medidas estadísticas en el análisis de datos

- B. Distribuciones estadísticas fundamentales e interpretación
  - **Interpretación de tendencias en diferentes contextos.**
    - **D. Contexto A lo Largo del Tiempo (Series Temporales).** Estudia cómo cambia una variable con el tiempo para identificar tendencias, ciclos y variaciones.
      - Tendencia gaussiana: Los valores se concentran alrededor de la media y hay menos valores extremos. Significa que los valores cercanos al promedio son más frecuentes. Gráfico: histograma con forma de campana. En una serie temporal, los valores pueden fluctuar alrededor de la media si siguen una distribución aproximadamente gaussiana.
      - Tendencia uniforme: Los valores presentan una frecuencia similar a lo largo del tiempo. Significa que no hay valores claramente predominantes. Gráfico: histograma con barras de alturas similares; en una gráfica temporal, los valores fluctúan sin una concentración marcada.

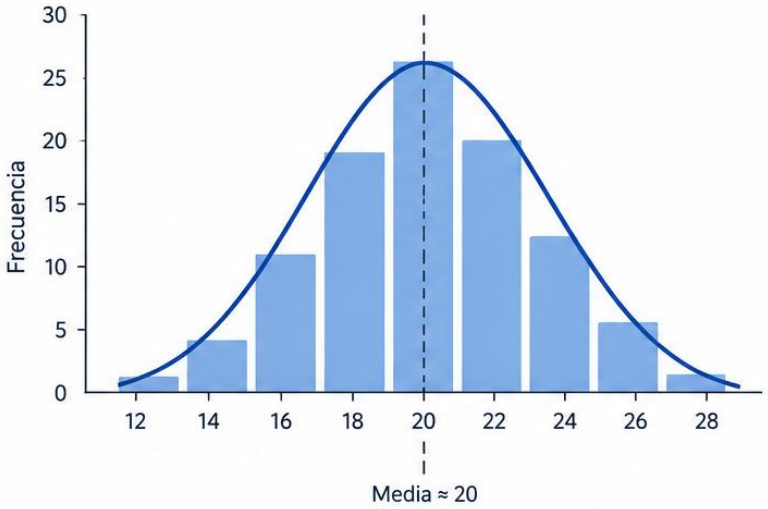
CHAPTER 3 – STATISTICAL ANALYSIS

Ejemplo de tendencia gaussiana en el contexto a lo largo del tiempo
(Series temporales)

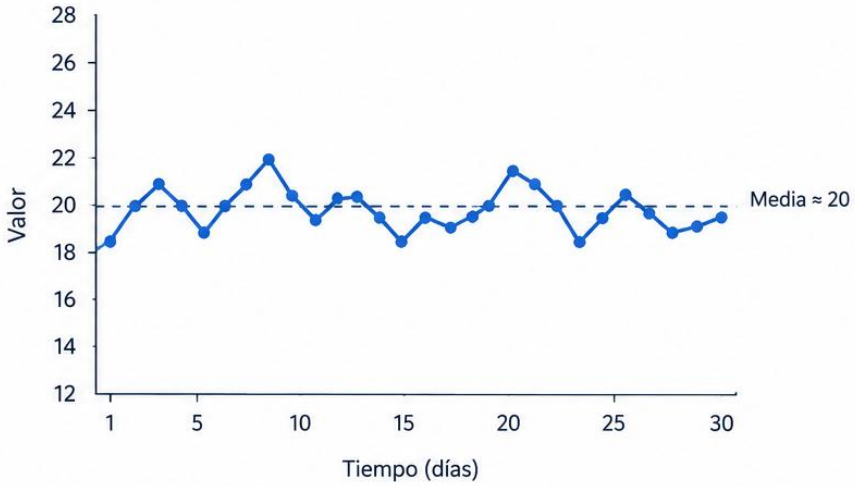
¿Qué significa?

Los valores se concentran alrededor de la media y disminuyen hacia los extremos.
Esto significa que los valores cercanos al promedio son más frecuentes que los extremos.

Histograma (distribución de los valores)



Serie temporal (valores a lo largo del tiempo)



En resumen:

En este ejemplo, los datos tienen una distribución gaussiana: la mayoría de los valores están cerca de la media (≈ 20) y hay menos valores en los extremos.
En la serie temporal, los valores fluctúan alrededor de la media, sin una tendencia creciente o decreiente clara.

CHAPTER 3 – STATISTICAL ANALYSIS

- Comprender y aplicar medidas estadísticas en el análisis de datos
- C. Medidas de confianza y fiabilidad de datos
  - **Intervalos de confianza**
    - Un intervalo de confianza del 95% para la media de una población significa que, si repitiéramos el muestreo muchas veces y construyéramos un intervalo de confianza en cada muestra del mismo modo, aproximadamente el 95% de esos intervalos contendrían el verdadero valor de la media poblacional.
    - El intervalo está compuesto por dos valores simétricos respecto a la media marcan un área:
      - El % incluido → nivel de confianza. Probabilidad de quedar dentro del área. Los más utilizados son 95% y 99%.
      - El % excluido → nivel de significación. Probabilidad de quedar fuera del área (50% por abajo; 50% por encima).
    - **El intervalo de confianza** → rango de valores entre los que está el nivel de confianza buscado.
      - Intervalos estrechos → mayor precisión.
      - Intervalos amplios → mayor incertidumbre.
      - El tamaño de muestra influye directamente en la confiabilidad.

Opción 1: Distribución normal (**se conoce la desviación estándar o típica**)

CHAPTER 3 – STATISTICAL ANALYSIS

- Comprender y aplicar medidas estadísticas en el análisis de datos

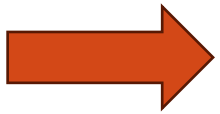
```
import numpy as np
import scipy.stats as st

# Simulamos una muestra grande (1000 usuarios)
np.random.seed(42) # Para que siempre dé el mismo resultado
datos_grandes = np.random.normal(loc=5, scale=1.5, size=1000)

media = np.mean(datos_grandes)
error_estandar = st.sem(datos_grandes)
nivel_confianza = 0.95

# Calculamos usando la distribución Normal (no requiere grados de libertad)
intervalo_z = st.norm.interval(confidence=nivel_confianza,
                               loc=media,
                               scale=error_estandar)

print(f"Media de la muestra grande: {media:.2f}")
print(f"Intervalo de confianza del 95% (Z): {intervalo_z}")
```



```
Media de la muestra grande: 5.03
Intervalo de confianza del 95% (Z):
(np.float64(4.937961107627906), np.float64(5.12003505983907))
```

Opción 2: Distribución t de Student (**no se conoce la desviación estándar**, es estimada)

CHAPTER 3 – STATISTICAL ANALYSIS

- Comprender y aplicar medidas estadísticas en el análisis de datos

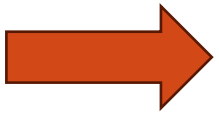
```python
import numpy as np
import scipy.stats as st


# 1. Creamos unos datos de ejemplo (por ejemplo, horas de uso del móvil)
datos = [4.5, 5.2, 6.0, 4.8, 5.1, 4.3, 5.5, 4.9, 5.2, 4.7]


# 2. Calculamos los datos básicos de la muestra
media = np.mean(datos)
error_estandar = st.sem(datos)  # Error estándar de la media (SEM)
grados_libertad = len(datos) - 1
nivel_confianza = 0.95


# 3. Calculamos el intervalo de confianza
intervalo = st.t.interval(confidence=nivel_confianza,
                          df=grados_libertad,
                          loc=media,
                          scale=error_estandar)


print(f"Media de la muestra: {media:.2f}")
print(f"Intervalo de confianza del 95%: {intervalo}")
```



```
Media de la muestra: 5.02
Intervalo de confianza del 95%:
(np.float64(4.665034293601551),
np.float64(5.3749657063984495))
```

CHAPTER 3 – STATISTICAL ANALYSIS

- Analizar y evaluar relaciones entre datos
- A. **Identificación de outliers** y análisis de correlaciones
  - **Outliers (valores atípicos)**
  - Los outliers son observaciones que se alejan significativamente del resto de los datos.
  - Posibles causas:
    - Errores de medición.
    - Variabilidad natural.
    - Datos anómalos o eventos excepcionales.

CHAPTER 3 – STATISTICAL ANALYSIS

- Analizar y evaluar relaciones entre datos
- A. **Identificación de outliers** y análisis de correlaciones
  - **Outliers (valores atípicos)**
  - Impacto de los outliers:
    - Distorsionan medias y desviaciones estándar.
    - Pueden afectar modelos estadísticos y predictivos.
    - Influyen en el análisis de correlación.
  - Métodos comunes de detección:
    - Boxplots.
    - Rango intercuartílico (IQR).
    - Z-score.

CHAPTER 3 – STATISTICAL ANALYSIS

- Analizar y evaluar relaciones entre datos
- A. Identificación de outliers y **análisis de correlaciones**
  - Correlación entre variables → La correlación mide la relación entre dos variables.
    - **Coeficiente de correlación de Pearson (r)**
    - El coeficiente de Pearson mide cuánto se alinean dos variables en una línea recta.
    - Por ejemplo, si quieres saber si a más horas de estudio corresponden mejores calificaciones, este número te lo dice.
    - Ventaja que tiene frente a la covarianza → el efecto de la escala.
      - La covarianza depende de las unidades: el cálculo de la covarianza entre peso y altura cambia si se utilizan diferentes unidades (peso en kilos o en gramos) → dificultad para interpretar.
      - El coeficiente de Pearson no se ve influido por las unidades → siempre te va a dar un resultado entre -1 y 1.

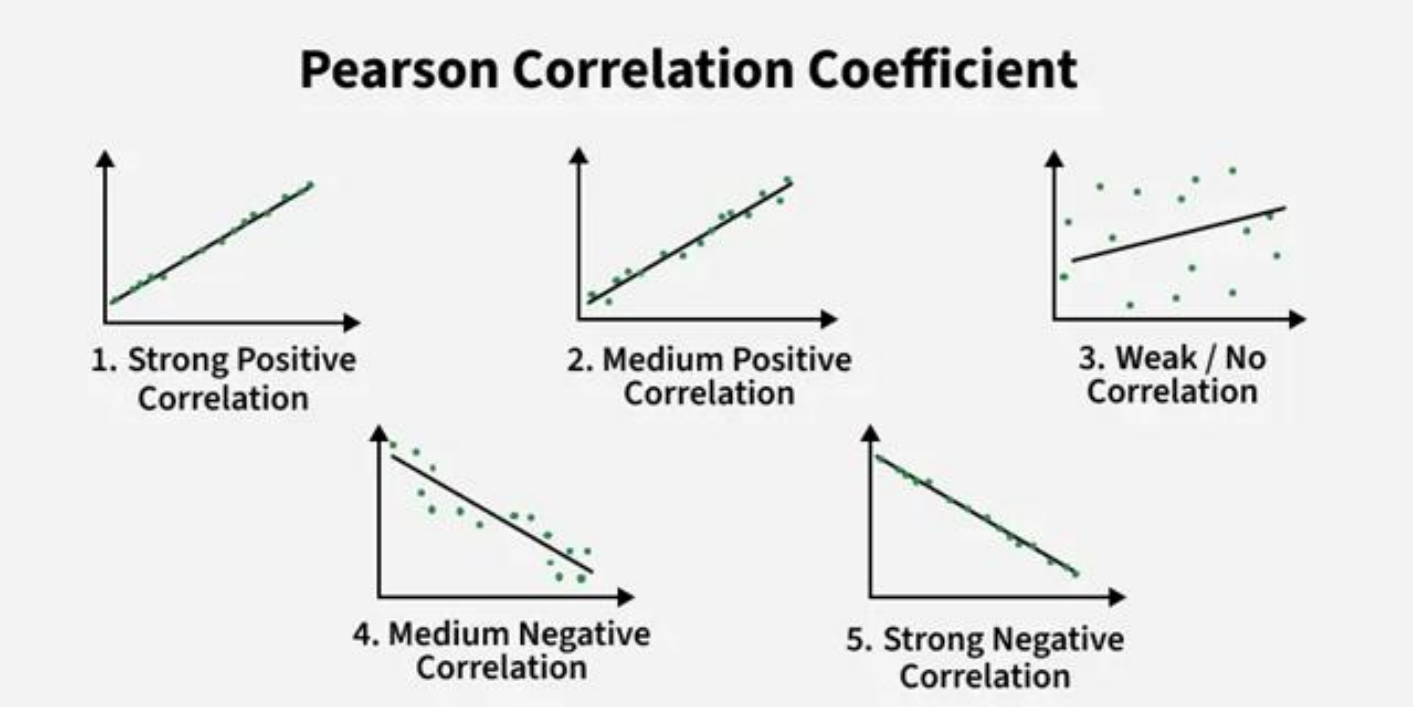
CHAPTER 3 – STATISTICAL ANALYSIS

- Analizar y evaluar relaciones entre datos
- A. Identificación de outliers y **análisis de correlaciones**
  - Correlación entre variables → La correlación mide la relación entre dos variables.
    - **Coeficiente de correlación de Pearson (r)**
      - Interpretación de Pearson's R

Valor de r	Interpretación
+1	Correlación positiva perfecta
0	Sin correlación lineal
-1	Correlación negativa perfecta

CHAPTER 3 – STATISTICAL ANALYSIS

- Analizar y evaluar relaciones entre datos
- A. Identificación de outliers y **análisis de correlaciones**
  - Correlación entre variables → La correlación mide la relación entre dos variables.



Fuente de la imagen: https://www.geeksforgeeks.org/maths/pearson-correlation-coefficient/

CHAPTER 3 – STATISTICAL ANALYSIS

- Analizar y evaluar relaciones entre datos
- **Coeficiente de correlación de Pearson (r) en Python+pandas → función corr.**
- **Ejemplo dos series:**

```
import pandas as pd

# Creamos un ejemplo rápido
data = {
    'Horas_Estudio': [2, 5, 7, 10, 12],
    'Calificacion': [50, 65, 78, 90, 95]
}
df = pd.DataFrame(data)

# Calculamos la correlación de Pearson
correlacion = df['Horas_Estudio'].corr(df['Calificacion'])

print(f"El coeficiente de Pearson es: {correlacion}")
# Resultado: 0.994 (Una relación positiva casi perfecta)
```

CHAPTER 3 – STATISTICAL ANALYSIS

- Analizar y evaluar relaciones entre datos
- **Coeficiente de correlación de Pearson (r) en Python+pandas → función corr.**
- **Ejemplo dataframe:**

```
import pandas as pd

data = {
    'Horas_Estudio': [2, 5, 7, 10, 12],
    'Calificacion': [50, 65, 78, 90, 95],
    'Asistencias': [10, 18, 20, 22, 25],
    'Nombre_Alumno': ['Ana', 'Luis', 'Pedro', 'Sofía', 'Carlos']
}
df = pd.DataFrame(data)

# Genera una tabla con todas las combinaciones posibles solo para
datos numéricos
matriz_correlacion =
df.select_dtypes(include='number').corr(method='pearson') #
'pearson' es el valor por defecto

print(matriz_correlacion)
```

	Horas_Estudio	Calificacion	Asistencias
Horas_Estudio	**1.000000**	0.991281	0.959210
Calificacion	0.991281	**1.000000**	0.966892
Asistencias	0.959210	0.966892	**1.000000**

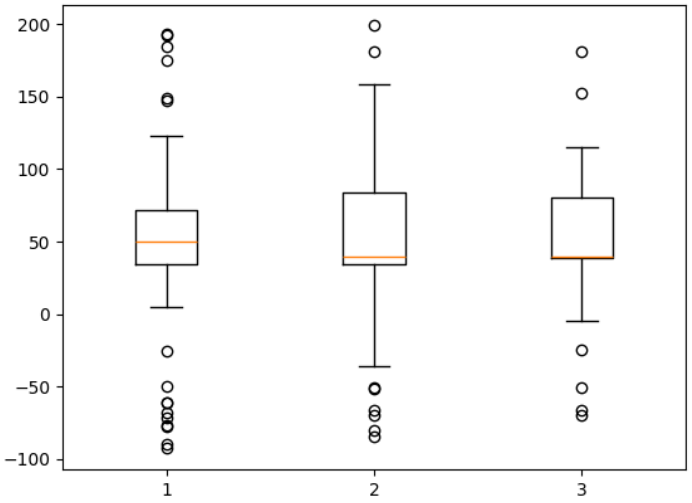


CHAPTER 3 – STATISTICAL ANALYSIS

- Analizar y evaluar relaciones entre datos
- A. Identificación de outliers y análisis de correlaciones
  - **Correlación entre variables → Coeficiente de correlación de Pearson (r)**
    - **Correlación positiva**
      - Ambas variables aumentan juntas.
      - Ejemplo: horas de estudio y calificación.
    - **Correlación negativa**
      - Una variable aumenta mientras la otra disminuye.
      - Ejemplo: velocidad y tiempo de viaje.
    - **Consideraciones importantes**
      - Correlación no implica causalidad.
      - Pearson mide relaciones lineales.
      - Los outliers pueden alterar significativamente el coeficiente.

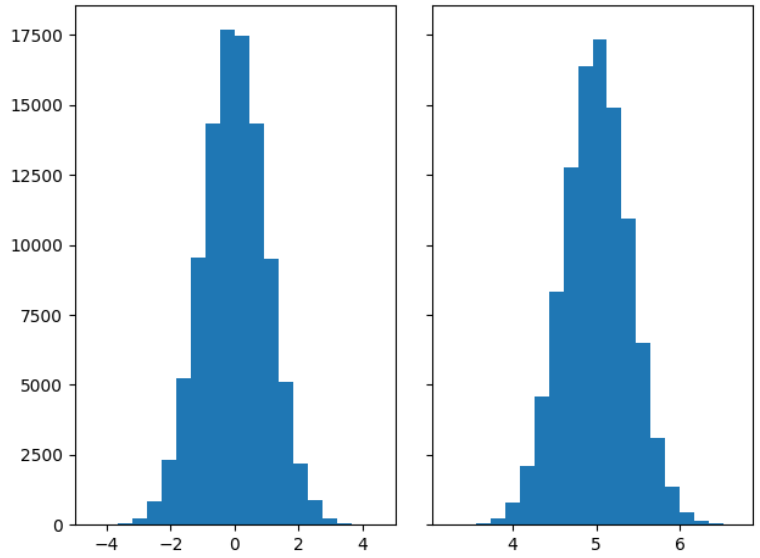
CHAPTER 3 – STATISTICAL ANALYSIS

- Analizar y evaluar relaciones entre datos
- B. Interpretación y evaluación crítica de gráficos
  - **Boxplot**
    - Objetivo → Visualizar distribución, dispersión y outliers.
    - Elementos principales:
      - Mediana.
      - Cuartiles.
      - Rango intercuartílico.
      - Valores atípicos.
    - Utilidad
      - Comparar grupos.
      - Detectar asimetrías y anomalías.



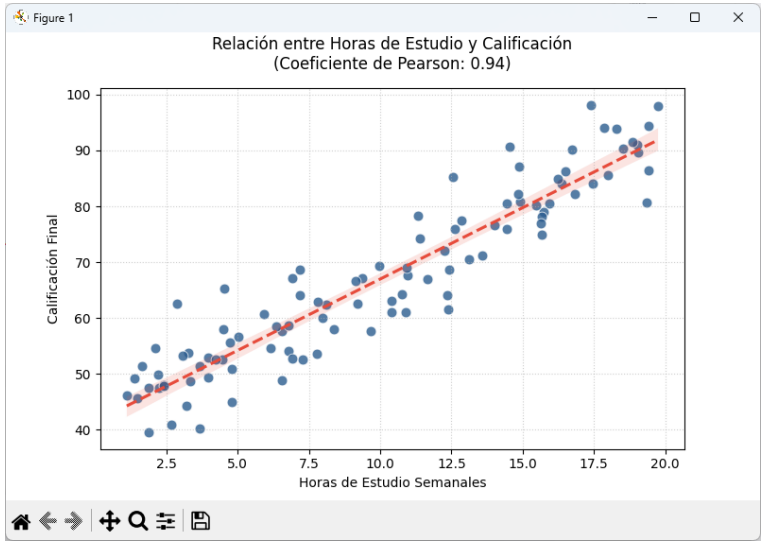
CHAPTER 3 – STATISTICAL ANALYSIS

- Analizar y evaluar relaciones entre datos
- B. Interpretación y evaluación crítica de gráficos
  - **Histograma**
    - Objetivo → Representar la distribución de frecuencias.
    - Permite identificar:
      - Forma de la distribución.
      - Sesgo.
      - Concentración de datos.
      - Distribuciones normales o multimodales.
    - Interpretación
      - Barras altas → mayor frecuencia.
      - Distribución simétrica o asimétrica.



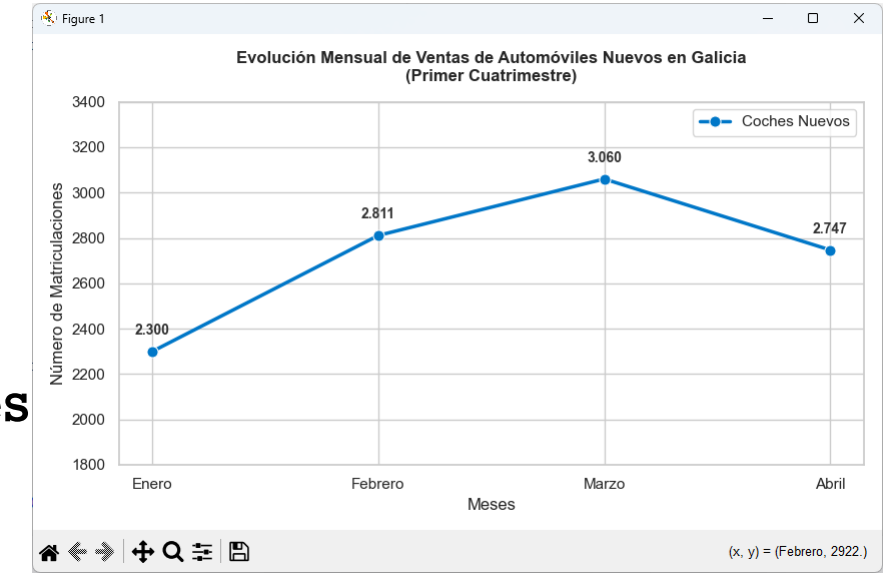
CHAPTER 3 – STATISTICAL ANALYSIS

- Analizar y evaluar relaciones entre datos
- B. Interpretación y evaluación crítica de gráficos
  - **Scatterplot** (diagrama de dispersión)
    - Objetivo → Mostrar relación entre dos variables.
    - Permite detectar:
      - Correlaciones positivas o negativas.
      - Tendencias.
      - Agrupamientos.
      - Outliers.
    - Interpretación
      - Patrón ascendente → correlación positiva.
      - Patrón descendente → correlación negativa.
      - Sin patrón → baja correlación.

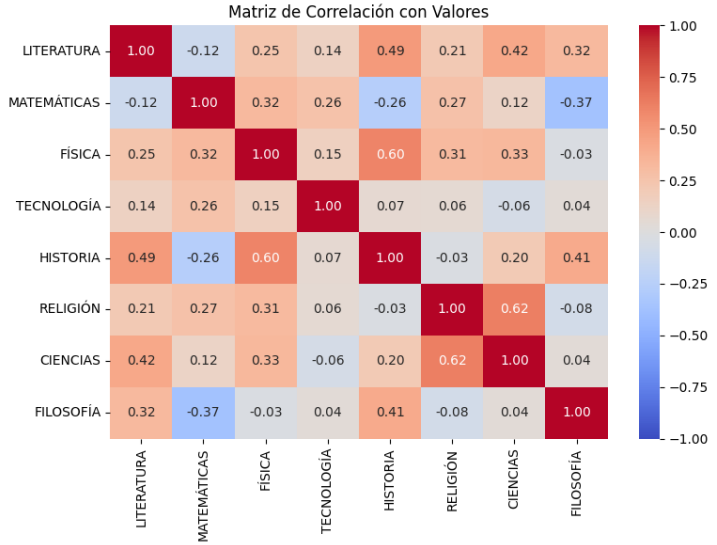


CHAPTER 3 – STATISTICAL ANALYSIS

- Analizar y evaluar relaciones entre datos
- B. Interpretación y evaluación crítica de gráficos
  - **Lineplot** (gráfico de líneas)
    - Objetivo→Visualizar cambios a lo largo del tiempo.
    - Aplicaciones
      - Series temporales.
      - Evolución de métricas.
      - Tendencias y estacionalidad.
    - Interpretación
      - Pendientes ascendentes o descendentes
      - Cambios bruscos.
      - Ciclos repetitivos.



CHAPTER 3 – STATISTICAL ANALYSIS



- Analizar y evaluar relaciones entre datos
- B. Interpretación y evaluación crítica de gráficos
  - **Correlation Heatmap**
    - Objetivo → Visualizar correlaciones entre múltiples variables.
    - Características
      - Utiliza colores para representar intensidad y dirección de correlaciones.
      - Facilita detectar relaciones fuertes o redundancias.
      - Interpretación
        - Valores cercanos a +1 → correlación positiva fuerte.
        - Valores cercanos a -1 → correlación negativa fuerte.
        - Valores cercanos a 0 → relación débil.

CHAPTER 3 – STATISTICAL ANALYSIS

- Analizar y evaluar relaciones entre datos
- B. Interpretación y evaluación crítica de gráficos
  - Evaluación crítica de visualizaciones
    - Al interpretar gráficos se debe considerar:
      - Calidad y tamaño de la muestra.
      - Presencia de outliers.
      - Escalas utilizadas.
      - Posibles sesgos visuales.
      - Contexto de los datos.
  - Idea clave → el análisis de relaciones entre variables y la correcta interpretación de gráficos permiten descubrir patrones, detectar anomalías y obtener conclusiones fundamentadas a partir de los datos.

CHAPTER 3 – STATISTICAL ANALYSIS

Inferential Statistics

CHAPTER 3 – STATISTICAL ANALYSIS

- Bootstrapping para distribuciones muestrales
- A. Fundamentos teóricos y principios estadísticos del bootstrapping
  - **Bootstrapping** es una técnica de remuestreo que permite estimar la distribución muestral utilizando únicamente la muestra disponible.
  - Se basa en realizar múltiples muestras aleatorias con reemplazo a partir de los datos originales → **Se genera una nueva muestra**
  - **Cada nueva muestra tiene el mismo tamaño que la muestra original**.
  - Permite estimar:
    - Media
    - Varianza
    - Error estándar
    - Intervalos de confianza
    - Sesgo estadístico
  - Ventajas:
    - No requiere asumir normalidad.
    - Útil cuando el tamaño muestral es pequeño o la distribución es desconocida.

CHAPTER 3 – STATISTICAL ANALYSIS

- Bootstrapping para distribuciones muestrales
- B. Diferencias entre datos discretos y continuos en bootstrapping
  - **Datos discretos**
    - Valores contables o categóricos.
    - Ejemplos:
      - Número de errores
      - Respuestas Sí/No
      - Cantidad de clientes
    - En bootstrapping:
      - Se remuestran observaciones exactas.
      - Puede haber muchas repeticiones del mismo valor.

CHAPTER 3 – STATISTICAL ANALYSIS

- Bootstrapping para distribuciones muestrales
- B. Diferencias entre datos discretos y continuos en bootstrapping
  - **Datos continuos**
    - Valores medibles en escalas continuas.
    - Ejemplos:
      - Peso
      - Temperatura
      - Tiempo
    - En bootstrapping:
      - Se preserva la variabilidad de la distribución original.
      - Adecuado para estimar estadísticas complejas.

CHAPTER 3 – STATISTICAL ANALYSIS

- Bootstrapping para distribuciones muestrales
- C. Situaciones donde el bootstrapping es efectivo
  - Casos recomendados
    - Tamaños muestrales pequeños o moderados.
    - Distribuciones desconocidas o no normales.
    - Estadísticos difíciles de modelar analíticamente.
    - Problemas de inferencia en machine learning y ciencia de datos.
  - Aplicaciones comunes
    - Estimación de intervalos de confianza.
    - Validación de modelos predictivos.
    - Comparación de medias o medianas.
  - Limitaciones
    - Menos efectivo con muestras muy pequeñas y poco representativas.
    - Sensible a valores atípicos extremos.
    - Puede requerir alto costo computacional.

CHAPTER 3 – STATISTICAL ANALYSIS

- Bootstrapping para distribuciones muestrales
- D. Aplicación práctica de bootstrapping con Python
  - Flujo básico
    - Seleccionar una muestra original.
    - Generar múltiples remuestras con reemplazo.
    - Calcular un estadístico en cada remuestra.
    - Construir la distribución muestral estimada.
    - Analizar resultados e intervalos de confianza.

PROCEDIMIENTO BOOTSTRAP

El bootstrap permite estimar la distribución muestral de un estadístico a partir de la muestra observada mediante **remuestreo con reemplazo.**

1 MUESTRA ORIGINAL

Tenemos una muestra de tamaño n extraída de la población.

Ejemplo de datos

4	7	2	9	6
3	5	8	1	10

Tamaño de la muestra: $n = 10$
Estadístico de interés: $\hat{\theta}$
(ej. media, mediana, proporción, etc.)

2 REMUESTREO CON REEMPLAZO

Generamos una muestra bootstrap tomando n observaciones **CON REEMPLAZO** de la muestra original.

Cada observación puede aparecer varias veces o no aparecer.

Ejemplo de una muestra bootstrap

7	2	7	5	1	10	3	7	2	6

Tamaño: $n = 10$

3 CALCULAR EL ESTADÍSTICO

Calculamos el estadístico de interés en la muestra bootstrap.

$$\hat{\theta}_1^* = s(D_1^*)$$

Donde D_1^* es la primera muestra bootstrap y $s(\cdot)$ es el estadístico (ej. media).

4 REPETIR B VECES

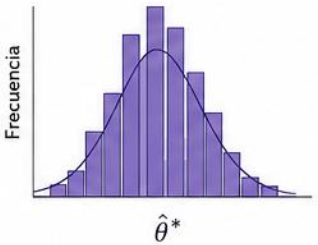
Repetimos los pasos 2 y 3 un gran número de veces (B), obteniendo B muestras bootstrap y sus estadísticos.

$$\begin{aligned} D_1^* &\rightarrow \hat{\theta}_1^* \\ D_2^* &\rightarrow \hat{\theta}_2^* \\ D_3^* &\rightarrow \hat{\theta}_3^* \\ &\vdots \quad \vdots \\ D_B^* &\rightarrow \hat{\theta}_B^* \end{aligned}$$

Ejemplo: B = 5,000

5 DISTRIBUCIÓN BOOTSTRAP

Con los B estadísticos obtenidos, construimos la distribución bootstrap aproximada.



¿PARA QUÉ SIRVE LA DISTRIBUCIÓN BOOTSTRAP?

ESTIMAR EL ERROR ESTÁNDAR

La desviación estándar de los B estadísticos bootstrap es una estimación del error estándar.

$$SE_{boot}(\hat{\theta}) = \sqrt{\frac{1}{B-1}\sum_{b=1}^{B}(\hat{\theta}_b^* - \bar{\theta}^*)^2}$$

CONSTRUIR INTERVALOS DE CONFIANZA

Usamos los percentiles de la distribución bootstrap (método percentil).

$$IC_{100(1-\alpha)} = \left[Q_{\alpha/2}(\hat{\theta}^*),\ Q_{1-\alpha/2}(\hat{\theta}^*) \right]$$

Ejemplo: IC 95% → percentiles 2.5% y 97.5%

EVALUAR SESGO

Comparamos el promedio bootstrap con el estadístico original.

$$Sesgo_{boot} = \bar{\theta}^* - \hat{\theta}$$

donde $\bar{\theta}^* = \frac{1}{B}\sum_{b=1}^{B}\hat{\theta}_b^*$

OTRAS APLICACIONES

- Inferencia para estadísticos complejos
- Validación de modelos
- Estimación de métricas (AUC, RMSE, etc.)
- Estabilidad de coeficientes e importancia de variables

RESUMEN DEL PROCEDIMIENTO

1. Partimos de la muestra observada.
2. Generamos muchas muestras bootstrap (con reemplazo).
3. Calculamos el estadístico en cada muestra.
4. La distribución de esos estadísticos aproxima la distribución muestral.
5. Usamos esa distribución para hacer inferencia.

CHAPTER 3 – STATISTICAL ANALYSIS

- Bootstrapping para distribuciones muestrales
- D. Aplicación práctica de bootstrapping con Python
  - Ejemplo:

```python
import numpy as np

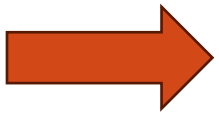
# Datos originales
data = np.array([10, 12, 13, 15, 18, 20])

# Número de remuestras
n_boot = 1000

# Almacenar medias
boot_means = []

for _ in range(n_boot):
    sample = np.random.choice(data, size=len(data), replace=True)
    boot_means.append(np.mean(sample))

# Resultados
print("Media bootstrap:", np.mean(boot_means))
print("Error estándar:", np.std(boot_means))
```



```
Media bootstrap: 14.601666666666667
Error estándar: 1.3186261790211813
```

CHAPTER 3 – STATISTICAL ANALYSIS

- Bootstrapping para distribuciones muestrales
- E. Fiabilidad y validez de los resultados
  - Fiabilidad
    - Aumenta con un mayor número de remuestras.
    - Resultados más estables con muestras representativas.
    - Normalmente se utilizan entre 1,000 y 10,000 iteraciones.
  - Validez
    - Depende de que la muestra original represente bien a la población.
    - Bootstrapping no corrige sesgos de muestreo.
    - Debe evaluarse:
      - Presencia de outliers
      - Dependencia entre observaciones
      - Tamaño de muestra suficiente
  - Interpretación crítica
    - Comparar resultados bootstrap con métodos tradicionales.
    - Revisar amplitud de intervalos de confianza.
    - Analizar sensibilidad de los resultados ante cambios en los datos.

CHAPTER 3 – STATISTICAL ANALYSIS

- Regresión lineal y logística: uso, aplicaciones y limitaciones
- A. Fundamentos teóricos y matemáticos de la regresión lineal
  - La regresión lineal modela la relación entre una variable dependiente continua y una o más variables independientes.
  - Objetivo:
    - Predecir valores y analizar relaciones lineales entre variables → **Predicción**
  - Aplicaciones comunes
    - Predicción de ventas.
    - Tendencias económicas.
    - Relación entre variables cuantitativas.

CHAPTER 3 – STATISTICAL ANALYSIS

- Regresión lineal y logística: uso, aplicaciones y limitaciones
- B. Conceptos y fundamentos de la regresión logística
  - La regresión logística se utiliza cuando la variable dependiente es categórica, normalmente binaria.
  - Objetivo
    - Estimar probabilidades de ocurrencia de una clase → **Clasificación**
  - Características
    - Salida entre 0 y 1.
    - Clasificación binaria:Sí/No
    - Éxito/Fracaso
  - Casos de uso
    - Diagnóstico médico.
    - Detección de fraude.
    - Clasificación de clientes.

CHAPTER 3 – STATISTICAL ANALYSIS

- Regresión lineal y logística: uso, aplicaciones y limitaciones
- C. Elección entre regresión lineal y logística
  - Cuando usar regresión lineal:
    - Variable objetivo numérica.
    - Relación aproximadamente lineal.
  - Cuando usar regresión logística:
    - Variable objetivo binaria o categórica.
    - Interesa estimar probabilidades o clases.

Aspecto	Regresión lineal	Regresión logística
Tipo de salida	Continua	Categórica
Objetivo	Predicción numérica	Clasificación
Ejemplo	Precio de vivienda	Aceptado/Rechazado

CHAPTER 3 – STATISTICAL ANALYSIS

- Regresión lineal y logística: uso, aplicaciones y limitaciones
- D. Datos discretos y continuos en regresión
  - Datos continuos
    - Valores medibles.
    - Utilizados típicamente en regresión lineal.
    - Ejemplos:
      - Temperatura
      - Ingresos
      - Altura
  - Datos discretos o categóricos
    - Valores contables o clases.
    - Utilizados en regresión logística.
    - Ejemplos:
      - Sí/No
      - 0/1
      - Aprobado/Reprobado

CHAPTER 3 – STATISTICAL ANALYSIS

- Regresión lineal y logística: uso, aplicaciones y limitaciones
- E. Aplicación práctica con Python → **Regresión lineal**

```python
from sklearn.linear_model import LinearRegression
import numpy as np

# Datos
X = np.array([[1], [2], [3], [4], [5]])
y = np.array([2, 4, 5, 4, 5])

# Modelo
model = LinearRegression()
model.fit(X, y)

# Predicción
prediction = model.predict([[6]])

print("Coeficiente:", model.coef_)
print("Intercepto:", model.intercept_)
print("Predicción:", prediction)
```

X son los datos de entrada
y los datos de salida (contínuos)

```
Coeficiente: [0.6]
Intercepto: 2.2
Predicción: [5.8]
```

CHAPTER 3 – STATISTICAL ANALYSIS

- Regresión lineal y logística: uso, aplicaciones y limitaciones
- E. Aplicación práctica con Python → **Regresión logística**

```
from sklearn.linear_model import LogisticRegression
import numpy as np

# Datos
X = np.array([[1], [2], [3], [4], [5]])
y = np.array([0, 0, 0, 1, 1])

# Modelo
model = LogisticRegression()
model.fit(X, y)

# Probabilidad de clase
prob = model.predict_proba([[3.5]]) # Probabilidad: [[0.5208689 0.4791311]]
# prob = model.predict([[3.5]]) # Probabilidad: [0]

print("Probabilidad:", prob)
```

X son los datos de entrada y los datos de salida (categóricos)

Probabilidad: [[0.5208689 0.4791311]]

Matriz de probabilidades

Predicción

CHAPTER 3 – STATISTICAL ANALYSIS

- Regresión lineal y logística: uso, aplicaciones y limitaciones
- F. Interpretación de resultados
  - **Regresión lineal**
    - Coeficientes
      - Indican cuánto cambia y por cada unidad de x.
      - Interpretación:
        - Cercano a 1 → buen ajuste.
        - Cercano a 0 → bajo poder explicativo.

CHAPTER 3 – STATISTICAL ANALYSIS

- Regresión lineal y logística: uso, aplicaciones y limitaciones
- F. Interpretación de resultados
  - **Regresión logística**
    - Coeficientes
      - Representan cambios en log-odds (probabilidades logarítmicas).
    - Métricas comunes:
      - Accuracy.
      - Precision.
      - Recall.
      - ROC-AUC.
    - Interpretación
      - Probabilidades mayores a un umbral → clasificación positiva.

CHAPTER 3 – STATISTICAL ANALYSIS

- Regresión lineal y logística: uso, aplicaciones y limitaciones
- G. Limitaciones, supuestos y sesgos
  - Limitaciones de la regresión lineal
    - Sensible a outliers.
    - No modela relaciones no lineales.
    - Problemas con multicolinealidad.
  - Limitaciones de la regresión logística
    - Requiere suficientes datos por clase.
    - Sensible a desbalance de clases.
    - Supone relación lineal en log-odds.

CHAPTER 3 – STATISTICAL ANALYSIS

- Regresión lineal y logística: uso, aplicaciones y limitaciones
- G. Limitaciones, supuestos y sesgos
  - Posibles sesgos
    - Sesgo de selección.
    - Variables omitidas.
    - Datos no representativos.
    - Sobreajuste (overfitting).
  - Impacto en resultados
    - Predicciones poco fiables.
    - Interpretaciones incorrectas.
    - Generalización limitada.

CHAPTER 3 – STATISTICAL ANALYSIS

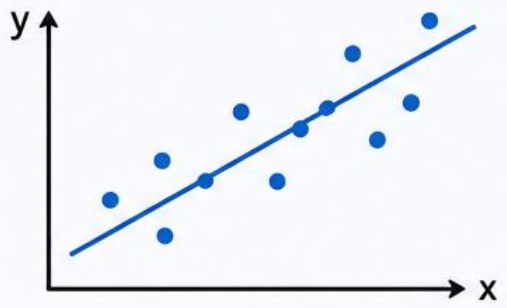
- Regresión lineal y logística: uso, aplicaciones y limitaciones
- Idea clave:
  - La regresión lineal y logística son herramientas fundamentales para predicción y análisis estadístico; elegir el modelo adecuado depende del tipo de datos, la naturaleza del problema y el cumplimiento de los supuestos estadísticos.

LOS 3 ALGORITMOS PRINCIPALES DE APRENDIZAJE AUTOMÁTICO

SUPERVISADO

1. REGRESIÓN

Predice un valor numérico continuo.



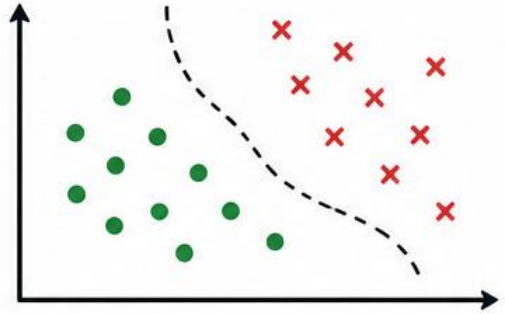
LOS 3 ALGORITMOS PRINCIPALES

1. Regresión Lineal
2. Regresión Polinómica
3. Regresión Ridge (L2)

SUPERVISADO

2. CLASIFICACIÓN

Predice una categoría o clase discreta.



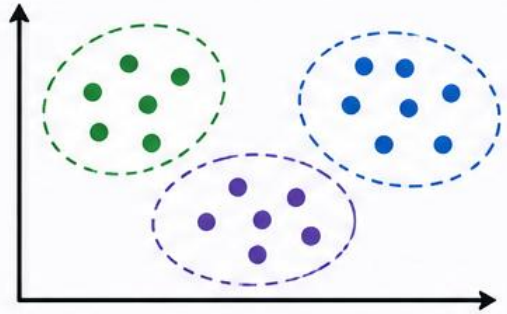
LOS 3 ALGORITMOS PRINCIPALES

1. Regresión Logística
2. Árboles de Decisión
3. Máquinas de Vectores de Soporte (SVM)

NO SUPERVISADO

3. AGRUPAMIENTO (CLUSTERING)

Agrupa datos similares sin usar etiquetas.



LOS 3 ALGORITMOS PRINCIPALES

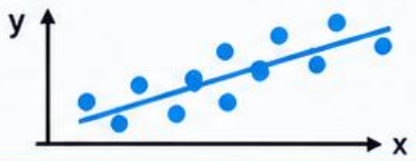
1. K-Means
2. DBSCAN
3. Clustering Jerárquico

IDEA CLAVE: Regresión = valores, Clasificación = categorías, = Agrupamiento = grupos.

Algoritmos de Regresión: ¿Para qué sirven y ejemplos?

Regresión Lineal

Encuentra una relación lineal entre una variable dependiente (y) y una o más variables (X).



¿Para qué sirve?

Predecir valores continuos (por ejemplo, ventas, precios o temperaturas).

Ejemplo de uso

Predecir el precio de una casa en función de su tamaño (m^2).

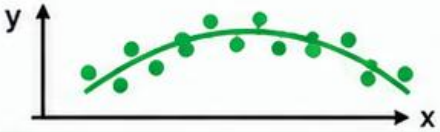
- Variable dependiente: precio
- Variable independiente: tamaño



Precio estimado: $320,000

Regresión Polinómica

Extiende la regresión lineal usando potencias de la variable (p. ej., x^2, x^3) para capturar relaciones no lineales.



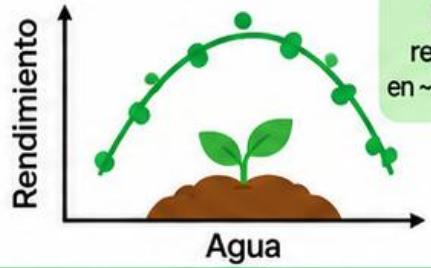
¿Para qué sirve?

Modelar patrones no lineales, como curvas o relaciones complejas.

Ejemplo de uso

Predecir el rendimiento de una planta según la cantidad de agua (relación curva).

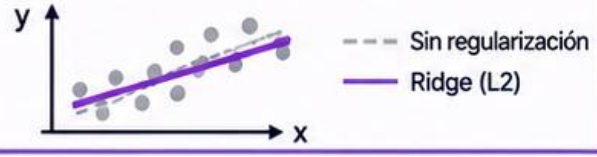
- Variables: agua
- Modelo: polinomio de grado 2 (o 3)



Máximo rendimiento en ~ 50% de agua

Regresión Ridge (L2)

Es una regresión lineal con regularización L2, que penaliza coeficientes grandes para evitar el **sobreajuste**.



¿Para qué sirve?

Mejorar la generalización del modelo, especialmente cuando hay muchas variables correlacionadas.

Ejemplo de uso

Predecir el riesgo de crédito con muchas características (ingresos, historial, etc.).

- Evita coeficientes extremos
- Reduce el sobreajuste

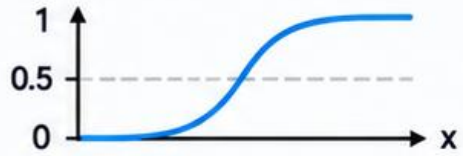


Predicción más estable y confiable

Algoritmos de Clasificación: ¿Para qué sirven y ejemplos?

Regresión Logística

Predice la probabilidad de pertenecer a una clase usando una función logística.



¿Para qué sirve?

Clasificar en dos o más clases (p. ej., sí/no, spam/no spam).

Ejemplo de uso

Predecir si un correo electrónico es spam.

- Variables: texto (características)
- Salida: spam o no spam



Spam

No spam

Árboles de Decisión

Clasifica usando decisiones jerárquicas basadas en preguntas sobre las variables.



¿Para qué sirve?

Clasificar datos de forma interpretable y manejar variables de distintos tipos (numéricas y categóriicas).

Ejemplo de uso

Determinar si un cliente comprará un producto.

- Variables: edad, ingresos, etc.
- Salida: comprará o no



Máquinas de Vectores de Soporte (SVM)

Encuentra el mejor hiperplano que separe las clases con el mayor margen posible.



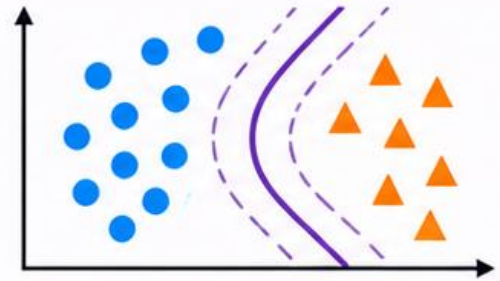
¿Para qué sirve?

Clasificar datos que no son linealmente separables (también con kernels para fronteras más complejas).

Ejemplo de uso

Distinguir entre correos legítimos y phishing.

- Variables: características del correo
- Salida: legítimo o phishing



Algoritmos de Clustering: ¿Para qué sirven y ejemplos?

K-Means

Divide los datos en un número determinado de grupos (K).



¿Para qué sirve?

Segmentar datos en grupos claros y bien definidos.

Ejemplo de uso

Una tienda divide a sus clientes en 3 grupos según su gasto:

- Clientes de bajo gasto
- Clientes de gasto medio
- Clientes de alto gasto



DBSCAN

Agrupa puntos con alta densidad y detecta valores atípicos (ruido).



¿Para qué sirve?

Encontrar grupos de forma flexible, incluso con formas irregulares, y detectar puntos anómalos.

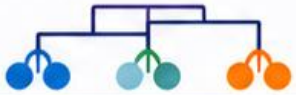
Ejemplo de uso

Una empresa de transporte identifica zonas con muchos pedidos y detecta pedidos atípicos en ubicaciones inusuales.



Clustering Jerárquico

Construye una jerarquía de grupos (árbol de agrupamiento).

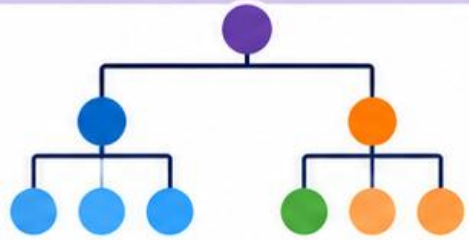


¿Para qué sirve?

Analizar la estructura de los grupos y decidir en qué nivel conviene dividirlos.

Ejemplo de uso

Una empresa agrupa productos por similitud y explora categorías más específicas según su jerarquía de grupos.



Mejor implementación de los algoritmos de aprendizaje automático

Librería y nombre de la función o clase en Python

1. Regresión

Algoritmo	Librería	Clase o función
Regresión lineal	scikit-learn	`sklearn.linear_model.LinearRegression`
Regresión polinómica	scikit-learn	`sklearn.preprocessing.PolynomialFeatures + sklearn.linear_model.LinearRegression`
Regresión Ridge (L2)	scikit-learn	`sklearn.linear_model.Ridge`

2. Clasificación

Algoritmo	Librería	Clase o función
Regresión logística	scikit-learn	`sklearn.linear_model.LogisticRegression`
Árboles de decisión	scikit-learn	`sklearn.tree.DecisionTreeClassifier`
Máquinas de vectores de soporte (SVM)	scikit-learn	`sklearn.svm.SVC`

3. Agrupamiento (Clustering)

Algoritmo	Librería	Clase o función
K-Means	scikit-learn	`sklearn.cluster.KMeans`
DBSCAN	scikit-learn	`sklearn.cluster.DBSCAN`
Clustering Jerárquico	SciPy	`scipy.cluster.hierarchy.AgglomerativeClustering`



Resumen de librerías recomendadas

scikit-learn | Implementa los nueve algoritmos y ofrece herramientas completas para el aprendizaje automático.

SciPy | Especialmente útil para clustering jerárquico.